

余剑

AI 应用开发实习生 (完整实现并部署 RAG 应用) | 南京优先, 可远程

电话: 17578999648 | 邮箱: yj2994762833@gmail.com | 南京 | 2027 届本科 (2023.09-2027.06)

GitHub: <https://github.com/yjmyy/ai-learning> | 上线项目: <https://ai-learning-rkcci4rwsv6aewbthzbvvc.streamlit.app/>

教育背景

南京邮电大学 · 网络工程 · 本科 · 2027 届

相关课程: 计算机网络、数据结构、操作系统、数据库原理

项目经历

1. RAG 知识库问答系统 (已上线) 2026.07 – 2026.08

Python | sentence-transformers (bge-small-zh-v1.5) | Chroma | FastAPI | Streamlit | DeepSeek API

- 独立设计并实现端到端 RAG 链路: 文档解析 → 分层切分 (300 字/块、50 字重叠, 保留段落语义) → bge 向量化 → Chroma 持久化向量库 → top-k 召回 → 重排 → LLM 生成带引用来源的回答
- 自建 12 条"问题+标准答案"评估集 (扩充中), 量化检索质量: top-1/3/5 命中率 75% / 83% / 92%, 以数据驱动切分与检索优化
- 设计回答溯源机制: 每条回答附引用编号与资料定位, 可一键查看原文, 保证可验证
- 使用 FastAPI 封装 REST 接口, Streamlit 构建交互界面, 部署至 Streamlit Cloud 公开访问; 全程 Git 管理、GitHub 开源
- 当前限制 (技术债务): 固定切分未语义感知、未做混合检索、评估规模较小; 下一版计划: 语义切分 + BM25 混合召回 + 评估集扩展

2. Agent 工具调用 Demo 2026.08

Python | Function Calling | JSON 协议

- 实现基于 JSON 协议的工具调用链路: 模型自主解析任务、决定调用 add/subtract/multiply 工具并返回结构化结果
- 掌握 Agent 核心机制 (Tool Use / ReAct 决策循环); 计划 9 月扩展多工具协同与基础状态管理

技能

语言与基础: Python (熟练)、SQL (基础)、HTTP 协议基础

AI 应用开发: 大模型 API 调用 (DeepSeek)、Prompt 工程、RAG 全链路、向量数据库 (Chroma)、Function Calling、检索评估 (eval)

工程与部署: FastAPI、Streamlit、Git/GitHub、Streamlit Cloud 部署

自我评价

- 专注大语言模型应用落地: 独立完成并上线 RAG 问答系统 (11 篇资料 → 254 块 → top-3 命中率 83%), 重视效果评估与可溯源
- 学习路径清晰: 正在深入 Agent 开发 (工具调用 → 规划 → 记忆 → 反思), 对评测工程化方向感兴趣
- 项目驱动、执行力强: 两周内完成"API 对话 → 向量检索 RAG → 网页部署上线"全链路

备注: 暂无实习经历, 以"已上线项目 + 评估数据"作为核心证明; 简历内容真实可验证。