

余剑

AI 应用开发实习生 (LLM 应用 / RAG / Agent)


南京邮电大学 · 网络工程 · 本科 · 2027 届 (2023.09 - 2027.06)

17578999648 | yj2994762833@gmail.com | 南京 (南京 onsite 优先, 可远程)

到岗 2026.09 下旬起 · 4-5 天/周 · 可连续实习 6 个月以上 (毕业可无缝转正)

上线项目: <https://ai-learning-fphncazxm3pnesntwchz6.streamlit.app/>

GitHub: <https://github.com/yjmyy/ai-learning>



项目经历

OfferAgent 求职智能体 (自研 + 自用, 持续迭代)

2026.09 至今

▸ 自研 8 工具 Agent 引擎并自用: 匹配分改成五维本地加权后同一岗位重复打分方差 0.00 (模型法平均波动 3.31 分); 工具守卫 6/6 拦截全部坏调用; 硬门槛自动拦下「硕士线 / 届别不符 / 方向偏算法」, 22 个真实岗位全链路跑通

Python · DeepSeek API · Streamlit · SQLite · ReAct / Function Calling / 多 Agent 协作

- 自研 Agent 引擎 (非框架封装): 8 工具统一 Schema 注册表 + ReAct 循环 + 预算上限防死循环; 新增 Plan / Reflect 两个节点 (先出 3-6 步计划并校验工具名合法性; 收尾自评目标是否达成, 解析失败保守兜底); 五类坏输出守卫 (非法 JSON / 未知工具 / 缺参 / 类型错 / 非对象) + 错误回填自纠错。
- 工具层两种来源: 内置注册表 + MCP: 自研 MCP server (stdio + JSON-RPC 2.0, 暴露 10 个工具), 任何支持 MCP 的客户端都能挂载; 执行类工具 (投递) 带 humanConfirm, 发送永远停在人确认——Supervisor 模式下投递工具不在子 Agent 工具集里。
- 匹配分结构化 (可复算、可解释): 把「让模型随口给分」换成本地五维加权 (硬技能 0.30 / 项目证据 0.25 / 地点 0.15 / 时间 0.15 / 门槛 0.15), 每维给出命中与缺失证据; 一致性评估: 重复打分方差 0.00 vs 模型法 3.31 分; 22 岗位实测自动筛出 6 个不该投的 (硕士线 / 届别不符 / 方向偏算法)。
- 记忆语义化 + 可观测: 事实与复盘写入向量记忆 (bge 语义召回, 支持模糊指代); trace 落盘 JSONL + 可视化页 (工具调用分布 / 覆盖率 / 运行时间线) + 成本计量。
- 产品闭环: 自我蒸馏 (15 题生成结构化画像) → 岗位匹配 → 话术生成 → 半自动投递 → 面试拷问 → 复盘写回画像, 全流程自研自用。
- 工程化: 11 页面应用, 数据 / AI / UI 三层拆分可独立测试; run_tests.py 统一测试入口 26 个测试 0 失败基线; 密钥走 Secrets 不落代码。

RAG 知识库问答系统 (已上线, 可点开验证)

2026.07 - 2026.08

▸ 28 篇资料 → 622 块向量库; 自建 54 条评估集做四模式消融, 混合检索 + 重排把 top-5 命中率从 86% 做到 98% (MRR 0.757→0.832); 拒答门禁使库外问题 100% 拦截、误拒 2%

Python · bge-small-zh-v1.5 · Chroma · FastAPI · Streamlit · DeepSeek API

- 端到端链路自己实现: 解析 (txt/md/pdf/docx/html/csv/xlsx, xlsx 手写 zip+XML 解析免依赖) → 结构感知切分 → bge 向量化 → Chroma → BM25 + 向量 RRF 融合 → 多特征重排 → 句级引用定位 (从命中块里挑出真正支撑答案的那句 + 字符偏移)。
- 评估驱动优化: 54 条评估集消融出「混合召回解决没召回、重排解决没排前面」的分工; 多查询改写实测性价比低 (top-5 反降、P95 +1.2s) 故不默认开——取舍有数据支撑。
- 可信层: 拒答阈值用评估集网格搜索校准 (库内最低覆盖率 0.211 / 库外最高 0.125 → 取 0.13); 数值型问题加答案级自检, 难负例拒答 0%→100%、误拒 2%。
- 工程化交付: FastAPI 服务化 (SSE 流式 + X-API-Key) + 增量索引 + trace 计量 (P95 1.4s、单次成本 0.0003 元) + Docker 一键起服务。

Agent 工具调用 (Function Calling 工程化)

2026.08

▸ 参数守卫拦截 5 类坏调用, 错误回填后模型可自纠错重试

Python · DeepSeek API · JSON 协议 / 参数合同校验

- 实现「模型自主决定调哪个工具 → 参数校验 → 执行 → 结构化结果回填」完整链路。
- 不做 happy path: 参数守卫拦截 5 类坏输出 (未知工具 / 缺参 / 类型错 / 非对象 / 非法 JSON), 失败时错误回填给模型自纠错; 已演进为 OfferAgent 的引擎核心。

教育背景

南京邮电大学 | 网络工程 | 本科 | 2027 届

相关课程: 计算机网络、数据结构、操作系统、数据库原理

技能

语言 / 基础 Python、SQL、HTTP 协议、数据结构与算法

Agent / 大模型应用 ReAct / Reflection / Plan-and-Execute 设计模式、多 Agent 协作 (Supervisor)、Function Calling 与参数合同校验、Prompt 工程、MCP 工具接入协议、DeepSeek API 全链路、RAG 全链路 (切分 / 向量化 / 召回 / 重排 / 生成)、Chroma、检索效果评估、LoRA 等微调方式原理

工程 / 部署 FastAPI、Streamlit、SQLite、Git / GitHub、Docker 容器化、LangGraph 编排、LangSmith 可观测、并发 / 异步编程、Streamlit Cloud 部署 + Secrets 管理

工具链 熟练使用 Codex / Cursor / Claude Code 等 AI 编程工具提效

求职说明

- 目标: AI 应用开发 / Agent 开发实习; 次选大模型应用评测方向。
- 暂无正式实习经历, 作品以「自研并自用的 Agent 系统 + 可复现量化评估 + 真实 debug 记录」为主; 简历每个数字、链接均可当场验证。

本简历由本人独立撰写, 项目与数据均可验证。