

余剑

求职意向: AI 应用开发实习生 (Agent 开发 / RAG 检索)

南京邮电大学 · 网络工程 · 本科 · 2027 届 (2023.09 - 2027.06)


电话: 17578999648 | 邮箱: yj2994762833@gmail.com | 南京 (可现场 / 远程)

可实习: 2026.09 起, 每周 4-5 天, 可连续 6 个月以上

GitHub: <https://github.com/yjmyai/ai-learning>

OfferAgent 演示: <https://ai-learning-c62pgpcfp7us6rzteltpj.streamlit.app/>

RAG 检索服务: <https://ai-learning-fphncazxmg3pnesntwchz6.streamlit.app/>



个人概述

独立完成两个自研项目: Agent 工具调用与工作流引擎 (OfferAgent)、RAG 检索问答服务; 均带自建评估集、压测报告与部署脚本, 代码与评估数据在 GitHub 仓库。

教育背景

南京邮电大学 | 网络工程 (本科) | 2023.09 - 2027.06

主修课程: 数据结构与算法、计算机网络、操作系统、数据库原理

自学: 大模型原理 (Transformer / Attention)、LoRA 微调原理、Agent 设计模式与评估方法

专业技能

编程语言: Python (主力, 熟悉 FastAPI / Streamlit)、Java (SpringBoot 3 + REST 接口开发, JDK 21)、SQL; 数据结构与算法 (哈希、双指针、滑动窗口、链表、二叉树、DFS / BFS、二分、回溯、动态规划)

大模型应用: RAG 全链路 (文档解析 / 切分 / 向量化 / 混合召回 / 重排 / 引用生成) 与检索效果评估; Agent (ReAct、Plan-and-Execute、Reflection、多 Agent 协作); Function Calling 与参数校验; MCP 协议; Prompt 工程

工程与部署: FastAPI、Streamlit、SQLite / Chroma、Docker、Git / GitHub Actions、SSE 流式输出、线程池并发、云端部署与密钥管理、AI 辅助开发工具链 (Codex / Cursor / Claude Code)

后端与数据 (Java): SpringBoot 3 / JDK 21、Spring Data JPA + Hibernate、MySQL (建表与索引、连接池 HikariCP、只读事务)、Redis (缓存 TTL、固定窗口限流)、REST 接口设计与入参校验、Maven

计算机基础: 计算机网络、操作系统、数据库原理

项目经历

OfferAgent 求职工作台 (独立开发, 持续迭代)

2026.09 - 至今

给求职场景做的个人工作台: 把「自我画像 → 岗位筛选 → 匹配打分 → 投递话术 → 投递记录 → 面试复盘」做成一条链路, 替代手工筛岗和逐条写话术。

把匹配打分从「模型自由给分」改成五维本地加权: 同一岗位重复打分标准差 2.36 分 → 0.00 分; 22 个真实岗位中自动拦下 8 个不该投的 (方向偏差 5 / 学历要求硕士 2 / 届别不符 1)。

Python · DeepSeek API · Streamlit · SQLite · LangGraph · MCP · Chroma / bge 向量检索

- 打分可复算 (原方案同一岗位打分会飘): 五维加权——硬技能 0.30 / 项目证据 0.25 / 地点 0.15 / 时间 0.15 / 门槛 0.15, 每维输出命中与缺失证据; 改之前模型直接给分对同一岗位最大波动 10 分, 改之后重复打分标准差 0.00。
- 坏输入不崩 (原方案一次非法调用就中断): 10 个工具统一 Schema 注册表 + Plan / Reflect 节点, 对 30 类正常与异常输入 (非法 JSON / 未知工具 / 缺参 / 类型错 / 非对象 / 大小写与空白变体) 做守卫评测, 判定 30/30 正确, 错误以结构化消息回填后模型自行修正重试。
- 外发可控 (投递动作不能交给模型自动执行): 自研 MCP 服务端 (stdio + JSON-RPC 2.0, 暴露同一套 10 个工具); 执行类工具标注 humanConfirm, 投递动作始终由人确认; 投递前重访岗位链接拦截失效岗位。
- 链路闭环: 15 题自我蒸馏产出结构化画像 → 岗位匹配 → 话术生成 → 半自动投递 → 面试拷问 → 复盘回写画像, 用 LangGraph 状态图串起各节点, 节点可单独测试。
- 对外 API 层 (Java/SpringBoot 3 + JDK 21 + MySQL + Redis): 岗位数据从 JSON 迁到 MySQL (JPA + HikariCP, 岗位名做主键让导入幂等), 热点查询走 Redis 缓存——同一请求第二次从 464ms 降到 51ms; 用 Redis 计数器做每 IP 每分钟限流 (超限 429 + Retry-After); AI 请求转发给 Python 服务 (连接 3s / 读 60s 分别配超时), 下游 4xx 透传状态码; 7 个接口与限流单元测试 0 失败。
- 工程化: bge 向量记忆 (三档降级保证离线可用)、线程池并发批量打分、调用 trace 落盘与可视化、Token 与成本计量; 11 个页面按数据 / AI / UI 三层拆分, 离线回归测试 0 失败, CI 覆盖单测 / 服务验收 / 镜像构建。

RAG 检索问答服务 (独立开发)

2026.07 - 2026.08

面向私有资料的检索问答服务: 文档入库后按语义检索并带引用回答, 检索质量用自建评估集量化, 不靠感觉判断好坏。

在 33 篇 / 740 块语料、240 条自建评估集上做两档消融 (质量指标两次跑批一致): 混合检索 R@5 93% / MRR 0.796; 加多特征重排 (默认档) R@5 95% / MRR 0.856。

Python · bge-small-zh-v1.5 · Chroma · FastAPI · Streamlit · DeepSeek API

- 重排的收益与代价都用数据说清: 同一份 240 条评估集上重排把 R@5 从 93% 提到 95%、MRR 从 0.796 提到 0.856, 代价是检索 P95 从约 60ms 升到约 85ms (延迟两次跑批有 ±20ms 波动, 质量指标稳定)——因此默认开启重排。
- 可信拒答 (避免「词都命中但答案不存在」仍作答): 拒答阈值在评估集上网格搜索校准, 再对数值型问题追加答案级自检; 库外问题误拒率 2%。
- 链路自研 (未套 LangChain 封装): 多格式解析 (txt / md / pdf / docx / html / csv / xlsx, 其中 xlsx 用 zip + XML 自解析, 不依赖第三方库) → 结构感知切分 → 向量化 → BM25 与向量 RRF 融合召回 → 多特征重排 → 句级引用定位 (返回支撑答案的句子与字符偏移)。
- 服务化与运维: FastAPI + SSE 流式 + API Key 鉴权 + 限流 + 存活 / 就绪探针; 启动预热把首个请求从 15.3s 降到 62ms; 按来源增量重建 (改一篇只重算一篇); trace 计量延迟与单次成本 (约 0.0003 元); 单机压测稳态约 20 QPS, Docker 一键启动。

其他

- 技术笔记: 持续维护技术学习笔记 (Agent 框架对比、Plan-and-Execute / Reflection 实现模式、RAG 检索与评估、HTTP 请求链路、工具调用协议)。
- 可复现证据: 两个项目的评估集、压测报告与一致性评估脚本随代码提交 (仓库 rag2/eval/、offeragent/docs/)。