

余剑

AI 应用开发实习生 (LLM 应用 / RAG / Agent)

南京邮电大学 · 网络工程 · 本科 · 2027 届 (2023.09 - 2027.06)


电话: 17578999648 | 邮箱: yj2994762833@gmail.com

南京 (可现场 / 远程) | 可实习: 2026.09 起, 每周 4-5 天, 可连续 6 个月以上

OfferAgent: <https://ai-learning-c62pgpcf7us6rztelatpj.streamlit.app/>

RAG 知识库: <https://ai-learning-fphncazmg3pnesntwchz6.streamlit.app/>

GitHub: <https://github.com/yjmyy/ai-learning>



个人概述

AI 应用开发方向 2027 届本科生, 独立完成 2 个可上线、量化的 LLM 应用项目: Agent 工具调用与 workflow (OfferAgent)、RAG 知识库问答系统。覆盖「Agent 引擎 → 检索链路 → 量化评估 → 服务化部署」完整链路, 代码开源、应用可在线运行。

教育背景

南京邮电大学 | 网络工程 (本科) | 2023.09 - 2027.06

主修课程: 数据结构与算法、计算机网络、操作系统、数据库原理

自学: 大模型原理 (Transformer / Attention)、LoRA 微调原理、Agent 设计模式与评估方法

专业技能

编程语言 : Python (主力, 熟悉 FastAPI / Streamlit)、SQL; 数据结构与算法 (哈希、双指针、滑动窗口、链表、二叉树、DFS / BFS、二分、回溯、动态规划)

大模型应用 : RAG 全链路 (文档解析 / 切分 / 向量化 / 混合召回 / 重排 / 引用生成) 与检索效果评估; Agent (ReAct、Plan-and-Execute、Reflection、多 Agent 协作); Function Calling 与参数校验; MCP 协议; Prompt 工程

工程与部署 : FastAPI、Streamlit、SQLite / Chroma、Docker、Git / GitHub Actions、SSE 流式输出、线程池并发、云端部署与密钥管理

计算机基础 : 计算机网络、操作系统、数据库原理

项目经历

OfferAgent 求职智能体 (个人项目, 自研并已上线) 2026.09 - 至今

将匹配打分从「模型自由给分」改为五维本地加权: 同一岗位重复打分标准差由 2.36 分降至 0.00 分; 工具守卫对 30 类输入的判定 30/30 正确。

Python · DeepSeek API · Streamlit · SQLite · LangGraph · MCP · Chroma / bge 向量检索

- 设计五维加权匹配打分: 硬技能 0.30 / 项目证据 0.25 / 地点 0.15 / 时间 0.15 / 门槛 0.15, 每个维度输出命中与缺失证据; 硬门槛自动拦截「硕士」「学历不符」「方向偏差」类岗位, 已在 22 个真实岗位上跑通全链路。
- 实现 Plan / Reflect 增强的 ReAct 引擎: 10 个工具统一 Schema 注册表 + 执行预算上限防死循环; Plan 先产出 3-6 步计划并校验工具名合法性, Reflect 收尾自评目标是否达成; 对 30 类正常与异常输入做守卫评测, 判定 30/30 正确, 错误以结构化消息回填后模型可自纠错。
- 实现 MCP 工具层: 基于 stdio + JSON-RPC 2.0 自研服务端, 对外暴露同一套 10 个工具; 执行类工具 (打开投递链接) 标注 humanConfirm, 投递动作始终由人确认。
- 工程化: 向量记忆 (bge 语义召回, 三档降级保证离线可用)、线程池并发批量打分、调用 trace 落盘与可视化、成本计量; 应用按数据 / AI / UI 三层拆分, 离线回归测试 0 失败, GitHub Actions CI 覆盖单测 / 服务验收 / 镜像构建。

RAG 知识库问答系统 (已上线) 2026.07 - 2026.08

在 32 篇 / 740 块自建语料上, 混合检索 R@5 达 93%、MRR 0.796、P@9 延迟 69ms; 拒答门禁对库外问题的误拒率为 1%。

Python · bge-small-zh-v1.5 · Chroma · FastAPI · Streamlit · DeepSeek API

- 自建 240 条评估集 (200 条可回答问题逐条绑定标准答案块, 40 条库外与难负例) 对检索做量化评估, 定位出「混合召回解决未召回到、重排解决未排到前面」的分工。
- 实现混合检索与重排链路: BM25 + 向量 RRF 融合召回后做多特征重排, 并在命中块内做句级引用定位 (返回支撑答案的句子与字符偏移, 前端可高亮)。
- 实现拒答门禁与答案级自检: 拒答阈值用评估集网格搜索校准; 对数值型问题增加答案级自检, 库外问题误拒率 1%。
- 端到端链路自研实现 (未使用 LangChain 封装): 多格式解析 (txt / md / pdf / docx / html / csv / xls, 其中 xls 用 zip + XML 自解析, 不依赖第三方库) → 结构感知切分 → 向量化 → 混合召回 → 重排 → 生成。
- 服务化与运维: FastAPI + SSE 流式输出 + API Key 鉴权 + 限流 + 存活 / 就绪探针; 启动预热使首个请求从 15.3s 降至 62ms, 单机压测稳态约 20 QPS, Docker 一键启动。