

余剑

求职意向：AI 应用开发实习生（Agent 开发 / RAG 检索）

南京邮电大学 · 网络工程 · 本科 · 2027 届（2023.09 - 2027.06）

电话：17578999648 | 邮箱：yj2994762833@gmail.com | 南京（可现场 / 远程）

可实习：2026.09 起，每周 4-5 天，可连续 6 个月以上

GitHub: <https://github.com/yjmyy/ai-learning>

OfferAgent 演示: <https://ai-learning-c62pgpcfp7us6rztelatpj.streamlit.app/>

RAG 检索服务: <https://ai-learning-fphncazxmg3pnesntwchz6.streamlit.app/>

个人概述

独立完成两个自研项目：Agent 工具调用与工作流引擎（OfferAgent）、RAG 检索问答服务；均带自建评估集、压测报告与部署脚本，代码与评估数据在 GitHub 仓库。

教育背景

南京邮电大学 | 网络工程（本科） | 2023.09 - 2027.06

主修课程：数据结构与算法、计算机网络、操作系统、数据库原理

自学：大模型原理（Transformer / Attention）、LoRA 微调原理、Agent 设计模式与评估方法

专业技能

编程语言：Python（主力，熟悉 FastAPI / Streamlit）、SQL；数据结构与算法（哈希、双指针、滑动窗口、链表、二叉树、DFS / BFS、二分、回溯、动态规划）

大模型应用：RAG 全链路（文档解析 / 切分 / 向量化 / 混合召回 / 重排 / 引用生成）与检索效果评估；Agent（ReAct、Plan-and-Execute、Reflection、多 Agent 协作）；Function Calling 与参数校验；MCP 协议；Prompt 工程

工程与部署：FastAPI、Streamlit、SQLite / Chroma、Docker、Git / GitHub Actions、SSE 流式输出、线程池并发、云端部署与密钥管理、AI 辅助开发工具链（Codex / Cursor / Claude Code）

计算机基础：计算机网络、操作系统、数据库原理

项目经历

OfferAgent 求职智能体（个人项目，持续迭代）

2026.09 - 至今

把匹配打分从模型自由给分改为五维本地加权：同一岗位重复打分标准差 2.36 分 → 0.00 分；22 个真实岗位中自动拦下 8 个（方向偏差法 5 / 学历要求硕士 2 / 届别不符 1）。

Python · DeepSeek API · Streamlit · SQLite · LangGraph · MCP · Chroma / bge 向量检索

- 设计五维加权匹配打分（硬技能 0.30 / 项目证据 0.25 / 地点 0.15 / 时间 0.15 / 门槛 0.15）：解决模型打分不可复现的问题，每个维度输出命中与缺失证据；22 个真实岗位实测 12 个建议投递、8 个被硬门槛直接拦截。
- 实现 Plan / Reflect 增强的 ReAct 引擎：10 个工具统一 Schema 注册表 + 执行预算上限防死循环；Plan 先产出 3-6 步计划并校验工具名合法性，Reflect 收尾自评目标是否达成；对 30 类正常与异常输入做守卫评测，判定 30/30 正确，错误以结构化消息回填后模型自行修正。
- 实现 MCP 工具层与投递状态机：基于 stdio + JSON-RPC 2.0 自研服务端，暴露同一套 10 个工具；用 LangGraph 状态图编排「链接核验 → 匹配打分 → 话术生成 → 投递 → 记录回写」，投递前重访岗位链接拦截失效岗位；执行类工具标注 humanConfirm，投递动作始终由人确认。
- 完成产品闭环：15 题自我蒸馏生成结构化画像 → 岗位匹配 → 投递话术 → 半自动投递 → 面试拷问 → 复盘回写画像；画像可渲染为交互式数字分身页，用于面试演示。
- 工程化与运维：bge 向量记忆（三档降级保证离线可用）、线程池并发批量打分、调用 trace 落盘与可视化、成本计量；11 个页面按数据 / AI / UI 三层拆分，离线回归测试 0 失败，CI 覆盖单测 / 服务验收 / 镜像构建。

RAG 检索问答服务（个人项目）

2026.07 - 2026.08

自建 240 条评估集（200 条可回答 + 40 条库外与难负例）：在 33 篇 / 740 块语料上混合检索 R@5 93%、MRR 0.796、P99 延迟 69ms；库外问题误拒率 1%。

Python · bge-small-zh-v1.5 · Chroma · FastAPI · Streamlit · DeepSeek API

- 设计并实现混合检索 + 重排链路：BM25 与向量用 RRF 融合召回后做多特征重排，并在命中块内做句级引用定位（返回支撑答案的句子与字符偏移，前端可高亮）。
- 自建 240 条评估集做消融评测（200 条可回答问题逐条绑定标准答案块，40 条库外与难负例）：量化定位「混合召回解决未召回到、重排解决未排到前面」的分工；多查询改写实测性价比低（延迟明显上升、精度未提升）故默认关闭。
- 实现拒答门禁与答案级自检：拒答阈值在评估集上网格搜索校准；对数值型问题追加答案级自检，库外问题误拒率 1%。
- 端到端链路自研实现（未使用 LangChain 封装）：多格式解析（txt / md / pdf / docx / html / csv / xlsx，其中 xlsx 用 zip + XML 自解析，不依赖第三方库）→ 结构感知切分 → 向量化 → 混合召回 → 重排 → 生成。
- 服务化与运维：FastAPI + SSE 流式输出 + API Key 鉴权 + 限流 + 存活 / 就绪探针 + 增量索引（改一篇只重算一篇）+ trace 计量（端到端延迟与单次成本约 0.0003 元）；启动预热把首个请求从 15.3s 降到 62ms，单机压测稳态约 20 QPS，Docker 一键启动。

其他

- 技术笔记：持续维护技术学习笔记（Agent 框架对比、Plan-and-Execute / Reflection 实现模式、RAG 检索与评估、HTTP 请求链路、工具调用协议）。
- 可复现证据：两个项目的评估集、压测报告与一致性评估脚本随代码提交（仓库 rag2/eval/、offeragent/docs/）。