



联系方式

南京邮电大学 · 网络工程 · 本科 · 2027 届 (2023.09–2027.06)
电话: 17578999648 | 邮箱: yj294762833@gmail.com | 南京 (可现场 / 远程)
可实习: 2026.09 起, 每周 4–5 天, 可连续 6 个月以上

技能

编程语言

Python (主力, 熟悉 FastAPI / Streamlit)、SQL; 数据结构与算法 (哈希、双指针、滑动窗口、链表、二叉树、DFS / BFS、二分、回溯、动态规划)

大模型应用

RAG 全链路 (文档解析 / 切分 / 向量化 / 混合召回 / 重排 / 引用生成) 与检索效果评估; Agent (ReAct、Plan-and-Execute、Reflection、多 Agent 协作); Function Calling 与参数校验; MCP 协议; Prompt 工程

工程与部署

FastAPI、Streamlit、SQLite / Chroma、Docker、Git / GitHub Actions、SSE 流式输出、线程池并发、云端部署与密钥管理、AI 辅助开发工具链 (Codex / Cursor / Claude Code)

计算机基础

计算机网络、操作系统、数据库原理

余剑

求职意向: AI 应用开发实习生 (Agent 开发 / RAG 检索)

GitHub: <https://github.com/yjmyai/ai-learning>

OfferAgent 演示: <https://ai-learning-c62pgpcfp7us6rztelapj.streamlit.app/>

RAG 检索服务: <https://ai-learning-fphncazxm3pnesntwchz6.streamlit.app/>

个人概述

独立完成两个自研项目: Agent 工具调用与工作流引擎 (OfferAgent)、RAG 检索问答服务; 均带自建评估集、压测报告与部署脚本, 代码与评估数据在 GitHub 仓库。

教育背景

南京邮电大学 | 网络工程 (本科) | 2023.09 – 2027.06

主修课程: 数据结构与算法、计算机网络、操作系统、数据库原理

自学: 大模型原理 (Transformer / Attention)、LoRA 微调原理、Agent 设计模式与评估方法

项目经历

OfferAgent 求职智能体 (个人项目, 持续迭代)

2026.09 – 至今

把匹配打分从模型自由给分改为五维本地加权: 同一岗位重复打分标准差 2.36 分 → 0.00 分; 22 个真实岗位中自动拦下 8 个 (方向偏差 5 / 学历要求硕士 2 / 属相不符 1)。

Python · DeepSeek API · Streamlit · SQLite · LangGraph · MCP · Chroma / bge 向量检索

- 设计五维加权匹配打分 (硬技能 0.30 / 项目证据 0.25 / 地点 0.15 / 时间 0.15 / 门槛 0.15): 解决模型打分不可复现的问题, 每个维度输出命中与缺失证据; 22 个真实岗位实测 12 个建议投递、8 个被硬门槛直接拦截。
- 实现 Plan / Reflect 增强的 ReAct 引擎: 10 个工具统一 Schema 注册表 + 执行预算上限防死循环; Plan 先产出 3–6 步计划并校验工具名合法性, Reflect 收尾自评目标是否达成; 对 30 类正常与异常输入做守卫评测, 判定 30/30 正确, 错误以结构化消息回填后模型自行修正。
- 实现 MCP 工具层与投递状态机: 基于 stdio + JSON-RPC 2.0 自研服务端, 暴露同一套 10 个工具; 用 LangGraph 状态图编排「链接校验 → 匹配打分 → 话术生成 → 投递 → 记录回写」, 投递前重访岗位链接拦截失效岗位; 执行类工具标注 humanConfirm, 投递动作始终由人确认。
- 完成产品闭环: 15 题自我蒸馏生成结构化画像 → 岗位匹配 → 投递话术 → 半自动投递 → 面试拷问 → 复盘回写画像; 画像可渲染为交互式数字分身页, 用于面试演示。
- 工程化与运维: bge 向量记忆 (三档降级保证离线可用)、线程池并发批量打分、调用 trace 落盘与可视化、成本计量; 11 个页面按数据 / AI / UI 三层拆分, 离线回归测试 0 失败, CI 覆盖单测 / 服务验收 / 镜像构建。

RAG 检索问答服务 (个人项目)

2026.07 – 2026.08

自建 240 条评估集 (200 条可回答 + 40 条库外与难负例): 在 33 篇 / 740 块语料上混合检索 R@5 93%、MRR 0.796、P99 延迟 69ms; 库外问题误拒率 1%。

Python · bge-small-zh-v1.5 · Chroma · FastAPI · Streamlit · DeepSeek API

- 设计并实现混合检索 + 重排链路: BM25 与向量用 RRF 融合召回后做多特征重排, 并在命中块内做句级引用定位 (返回支撑答案的句子与字符偏移, 前端可高亮)。
- 自建 240 条评估集做消融评测 (200 条可回答问题逐条绑定标准答案块, 40 条库外与难负例): 量化定位「混合召回解决未召回到、重排解决未排到前面」的分工; 多查询改写实测性价比低 (延迟明显上升、精度未提升) 故默认关闭。
- 实现拒答门禁与答案级自检: 拒答阈值在评估集上网格搜索校准; 对数值型问题追加答案级自检, 库外问题误拒率 1%。
- 端到端链路自研实现 (未使用 LangChain 封装): 多格式解析 (txt / md / pdf / docx / html / csv / xlsx, 其中 xlsx 用 zip + XML 自解析, 不依赖第三方库) → 结构感知切分 → 向量化 → 混合召回 → 重排 → 生成。
- 服务化与运维: FastAPI + SSE 流式输出 + API Key 鉴权 + 限流 + 存活 / 就绪探针 + 增量索引 (改一篇只重算一篇) + trace 计量 (端到端延迟与单次成本约 0.0003 元); 启动预热把首个请求从 15.3s 降到 62ms, 单机压测稳态约 20 QPS, Docker 一键启动。