

余剑

AI 应用开发实习生 (LLM 应用 / RAG / Agent)

南京邮电大学 · 网络工程 · 本科 · 2027 届 (2023.09-2027.06)
17578999648 | yj2994762833@gmail.com | 南京 (onsite 优先, 可远程)
到岗 2026.09 下旬起 · 4-5 天/周 · 可连续实习 6 个月以上 (毕业可无缝转正)
上线项目: <https://ai-learning-fphncaxmg3pnesntwchz6.streamlit.app/>
GitHub: <https://github.com/yjmyy/ai-learning>

项目经历

RAG 知识库问答系统 (已上线, 可点开验证) 2026.07 - 2026.08

11 篇资料 → 254 块向量库; 自建评估集实测 top-1 / top-3 / top-5 命中率 **75% / 83% / 92%**, 回答带引用溯源

Python | bge-small-zh-v1.5 | Chroma | FastAPI | Streamlit | DeepSeek API

- 独立实现端到端链路**: 文档解析 → 300 字/块切分 (重叠 50, 保留段落边界) → bge 向量化 → Chroma 持久化 → top-k 召回 → TF-IDF 重排 → 生成带引用编号的回答。全程自己写, 不套 LangChain 封装, 链路上任何一环出问题都能定位。
- 自建 12 条评估集量化检索质量**: 逐条记录 top-1/3/5 命中情况, 用同一套数据对比切分参数与重排策略, 把 "感觉还行" 变成可复现的数字 (样本量偏小, 正在扩到 50+ 条)。
- 定位并修复真实问题**: 切分把定义段稀释导致检索漂移 → 改为保留段落边界的分层切分; 修掉模型输出嵌套 JSON 被正则截断的 bug; 实现向量库离线缓存, 避免每次启动重载模型。
- 工程与交付**: FastAPI 封装接口 + Streamlit 页面 (含引用溯源面板), 部署到 Streamlit Cloud 公开访问; Git 管理, 仓库含完整代码与评估脚本。

Agent 工具调用 (Function Calling 工程化) 2026.08

参数守卫拦截 **5 类坏调用**, 错误回填后模型可自纠错重试

Python | DeepSeek API | JSON 协议 / 参数合同校验

- 实现 "模型自主决定调哪个工具 → 参数校验 → 执行 → 结构化结果回填" 的完整链路。
- 不做 happy path**: 把 "模型输出不可信" 当前提, 参数守卫拦掉未知工具 / 缺必填参数 / 类型错 / 返回非对象 / 非法 JSON 五类坏输出, 失败时把错误回填给模型自纠错, 而不是直接抛异常。
- 已集成进求职 Agent 项目继续迭代 (多工具协同 / 会话记忆 / 多轮规划在做)。

教育背景

南京邮电大学 | 网络工程 | 本科 | 2027 届
相关课程: 计算机网络、数据结构、操作系统、数据库原理

技能

语言 / 基础	Python (能独立写完整可运行程序)、SQL (基础)、HTTP 协议
大模型应用	模型 API 调用 (DeepSeek 全链路)、Prompt 工程、RAG 全链路 (切分 / 向量化 / 召回 / 重排 / 生成)、向量库 Chroma、Function Calling、检索效果评估
工程 / 部署	FastAPI、Streamlit、Git / GitHub、Streamlit Cloud 部署、依赖与密钥管理
正在补	Docker、LangChain / LangGraph、并发处理

求职说明

- 目标: AI 应用开发 / Agent 开发实习; 次选大模型应用评测方向。
- 暂无正式实习经历, 作品以「已上线项目 + 可复现的量化评估 + 真实 debug 记录」为主。
- 简历里每个数字、每条链接都可当场验证: 代码在 GitHub, 应用能打开, 评估脚本在仓库里。

本简历由本人独立撰写, 项目与数据均可验证。